

기억 쓰기 승인 규칙의 추가 실험 결과

추출기 개입과 LLM 검증기 비교 및 실제 음성 인식 데이터 진단

이번 보완은 두 질문에 답한다. 첫째, 기존 논문에서 설명한 정정 오류의 원인이 실제로 추출 결과의 누락인가. 둘째, 그 설명과 승인 규칙이 외부의 실제 음성 인식 데이터에서도 성립하는가. 검증기 비교는 첫 번째 보완에 함께 정리했다.

핵심 5사례에서는 추출 지침 수정 후 정정 성공이 1건에서 5건으로 늘었다. 반면 DSTC2에서는 엄격한 승인이 잘 못된 기록 3건을 막으면서 올바른 변경 17건도 막았다. 두 결과는 표현 누락과 실제 인식 불확실성을 구분해야 한다는 결론으로 연결된다.

1 핵심 5사례의 추출기 보완

무엇을 바꾸고 무엇을 고정했는가

Gemini 2.5 Flash의 과거 실패 사례 5개를 선택해 원래 추출 지침과 수정 지침을 비교했다. 수정은 명시적으로 인정된 정정을 해당 해석의 fact list에도 넣도록 요구한 것이다. 저장된 변경 제안, AGREE 규칙, 실행기, 평가 기준은 고정했다. 조건당 새 추출 1회인 사후 진단이다.

사례	정정 대상	원지침	수정 지침
CT01	고향 → 대구	성공	성공
CT42	고향 → 문경	보류	성공
CT45	연도 → 1993년	보류	성공
CT46	배운 사람 → 신 선생님	보류	성공
CT48	모임 장소 → 시민운동장	보류	성공

정정 성공 1/5 → 5/5 · AGREE 보류 4/5 → 0/5 · 참조 위반 0 → 0건

네 사례에서 원래 추출은 correction_witnesses에 새 값을 인정하면서도 두 해석의 fact list를 비워 두었다. 수정 후 양쪽 사실 목록에 정정 튜플이 들어가자 같은 AGREE가 쓰기를 승인했다. CT01은 원지침에서도 회복했으므로 수정 효과로 세지 않는다.

선택한 네 사례에서 정정 증거와 승인 입력 사이의 표현 누락을 확인했다. 이는 선택 사례의 국소적 메커니즘 근거다. CT01은 원지침에서도 성공했으므로 회복 효과에 포함하지 않는다. 참조는 기존 작성 기준이며 독립 사람 gold가 아니다.

2 LLM 검증기와 다른 모델에서의 비교

추출 지침 수정이 다른 모델에도 필요한가

Gemini 3.8 Flash는 저장된 자체 제안 48개에서 원지침과 수정 지침 모두 정정 11/11, 전체 상태 일치 47/48, 참조 위반 0건이었다. 이 표본에서는 같은 추출 보완의 추가 이득이 없었다. Gemini 2.5 Flash는 과거 실패 원인을 확인하는 사례로 유지하고, 새로운 모델에서도 같은 문제가 필수적으로 발생한다고 확대하지 않는다.

LLM 검증기를 실제 비교 기준으로 추가

Gemini 3.1 Pro가 세 모델 구성의 저장된 Review 제안을 각각 48개씩 검증했다. 공개 입력과 제안만 보고 승인 또는 보류하며, 값이나 정정 대상을 새로 만들 수 없다. 판정기는 비교 대상이고, 평가에는 기존 동결 참조를 사용했다. 별도 NLI 모델 실험은 수행하지 않았다.

제안 생성 모델	정책	정정 /11	필요 변경 /28	참조 위반 /48	전체 일치 /48
Gemini 2.5 Flash	Review	11	27	2	46
	WITNESS	11	27	1	47
	LLM 검증기	11	27	1	47
Gemini 3.8 Flash	Review	11	28	0	48
	WITNESS	11	27	0	47
	LLM 검증기	11	28	0	48
Qwen3 14B	Review	11	24	4	42
	WITNESS	11	24	3	43
	LLM 검증기	11	24	1	44

Review는 저장된 검토 후 제안을 실행한 조건이다. WITNESS와 LLM 검증기는 그 제안에 추가 승인 판단을 적용했다. 필요 변경은 긍정적 변경 대상 28개, 정정은 그중 정정 대상 11개를 분모로 한다.

LLM 검증기는 2.5 Flash에서 WITNESS와 같았고, 3.8 Flash에서는 WITNESS가 막았던 필요한 변경 1건을 보존했다. Qwen에서는 WITNESS 대비 참조 위반이 3건에서 1건으로 줄었다. 보고된 비영 차이의 쌍별 구간은 모두 0을 포함하므로 건수 차이를 기술하는 수준으로 해석한다.

추가 호출 비용과 결과 해석

추가 검증에는 144회 호출이 필요했고 평균 요청 지연은 4.39초였다. 저장된 제안을 재사용하면 제안 생성은 반복하지 않아도 되지만, LLM 검증 자체가 무료가 되는 것은 아니다. 기여는 결정적 규칙의 보편적 우월성이 아니라, 승인 경계를 분리해 다른 규칙과 LLM 검증기를 같은 제안 위에서 비교할 수 있다는 점이다.

3 DSTC2 실제 음성 인식 데이터 검증

공식 test의 서로 다른 48개 대화, 41명 화자에서 한 턱씩 선택했다. 요구 변경 24개, 명시적 대체 없는 부정 12개, 참조를 이용해 선정한 인식 오류 진단 12개다. 원래 live 10-best에서 빈 항목과 같은 문자열을 제외한 433개 후보를 사용했다. 표본은 진단용으로 선정되었으며 실제 발생 비율을 대표하지 않는다.

이전 공식 목표 상태를 초기 기억으로 주고, 현재 전사와 라벨은 생성 모델에 주지 않았다. 사람 검토 의미 라벨에서 유도된 공식 목표 상태와 결과를 비교했다. 영어 식당 도메인의 food·area·pricerange에 맞춘 구성 요소 진단이며, 전체 대화 추적이나 한국어 시니어 서비스 평가와는 단위가 다르다.

Gemini 3.1 Pro 정책	필요 변경 /36	새 잘못된 쓰기 /48	전체 목표 일치 /48
RAW 제안	23	3	33
ALLOW	23	3	33
AGREE	6	0	18
LITERAL	6	1	17
WITNESS	6	0	18

ALLOW는 AGREE가 보류한 CORRECT를 풀어 주는 조건이다. AGREE는 해석별 사실의 일치를, LITERAL은 문자열 포함을, WITNESS는 정정 증거의 조건을 확인한다. 같은 추출과 제안을 재사용했다.

안전성 이득과 변경 누락이 함께 나타났다

AGREE가 보류한 정정 20개 중 17개는 올바른 제안이고 3개는 잘못된 제안이었다. 원인은 추출값 불일치 10개, 일부 후보의 지지 또는 누락 10개였다. 모든 해석의 유효한 정정 증거가 있지만 사실 목록에서만 빠진 기존 5사례형 패턴은 0개였다.

ALLOW 대비 AGREE/WITNESS의 전체 목표 일치 차이는 -31.25%p였다(화자 클러스터 부트스트랩 95% 구간 -45.83~-16.33). 잘못된 새 쓰기 차이는 -6.25%p(-13.46~0.00)였다. 엄격한 승인의 전체 성능 향상으로 해석할 수 없다.

선정 유형	ALLOW	AGREE / WITNESS	LITERAL
요구 변경 24개	20/24	5/24	5/24
부정 12개	10/12	12/12	11/12
인식 오류 진단 12개	3/12	1/12	1/12

표의 값은 전체 목표 일치 수다. Gemini 3.8 Flash는 22/48개만 완결되어 별도 부분 결과로 보존했다. 전체 목표 일치는 RAW/ALLOW 9/22, 나머지 세 규칙 3/22였다. Pro의 48개 결과와 합산하거나 직접 순위를 매기지 않는다.

4 사례 분석과 데이터 이용 범위

단어가 있어도 사용자가 인정한 값은 아닐 수 있다

DSTC2_45의 실제 발화는 “i dont want chinese i want thai food”였다. 초기 기억은 이미 thai였지만 모든 인식 후보에 chinese가 들어 있었다. LITERAL은 chinese로 바꾸는 잘못된 제안을 승인했다. AGREE/WITNESS는 보류해 기존의 올바른 thai를 유지했다. 새 정답을 복원한 효과가 아니라 잘못된 변경을 막은 효과다.

반대로 DSTC2_07의 “how about vietnamese food”는 일부 후보에서 “how about you need food”로 인식되었다. ALLOW는 올바른 vietnamese 변경을 반영했지만, 엄격한 세 규칙은 이를 보류했다. 이 두 사례가 실제 인식 불확실성에서의 상충 관계를 보여 준다.

CareCall은 사람 연산 라벨 확보가 필요하다

논문에는 3명 중 2명의 다수결로 정한 PASS·REPLACE·APPEND·DELETE 라벨과 train 2,149개, validation 300개, test 300개가 보고되어 있다. 그러나 확인한 공식 공개 저장소에는 한국어 샘플과 자동 번역 영어 자료가 있고, 필요한 원본 연산 라벨과 공식 분할 파일은 없었다. 따라서 CareCall 모델 실험은 실행하지 않았다.

다음 실행에는 원본 한국어 메모리 쌍과 연산 라벨, 원본 ID, 대화·세션 연결 정보, 공식 분할, 해당 이용 조건이 필요하다. REPLACE에는 시간에 따른 변화와 세부 정보 추가도 포함되므로 전부를 과거 오류의 정정으로 분류할 수 없다.

결과 종합

통합 결론은 다음과 같다. 승인 규칙의 효과는 그 앞단에서 만들어진 증거의 형태와 불확실성의 원인에 달려 있다. 선택한 작성 사례에서는 추출 표현을 바로잡아 불필요한 보류를 해소했지만, 실제 ASR 후보가 서로 다를 때에는 정정 반영과 잘못된 쓰기 억제 사이의 상충이 나타났다. 같은 제안을 재사용하는 비교는 이 차이를 분리해 드러낸다.

공개 근거 자료

핵심 사례: [supplements/authored/paper_focal5_completion_20261004/](#)의 FOCAL_RESULT.json과 MECHANISM_TRACE.json. 검증기와 외부 검증의 결과·분석 방법·재현 절차는 [supplements/README.md](#)와 각 하위 폴더에 수록했다.

외부 출처: CareCall [github.com/naver-ai/carecall-memory](#) 및 [aclanthology.org/2022.findings-emnlp.276/](#); DSTC2 [github.com/matthen/dstc](#) 및 [aclanthology.org/W14-4337/](#).

본 보고서는 본 실험 이후 수집한 별도 진단 결과를 정리한다. 핵심 사례 개입, LLM 검증기 비교, 실제 ASR 진단은 서로 다른 표본과 절차를 사용하므로 점수를 합산하지 않는다.